



Звіт до лабораторної роботи №2

Варіант 1: Розпізнавання співу птахів

Огляд існуючих рішень

Загальний підхід до задачі: стандартний пайплайн для всіх BirdCLEF змагань складається з трьох ключових етапів: перетворення аудіо у мел-спектрограму, класифікація спектрограми згортковою нейронною мережею, та агрегація передбачень по часових фрагментах soundscape.

Огляд рішень BirdCLEF+ 2025

Переможці BirdCLEF+ 2025 використовували такі підходи:

- EfficientNet / ConvNeXt / BEiT як backbone для класифікації мел-спектрограм
- Pretrained аудіо-моделі: BirdNET, Pretrained Audio Neural Networks, AudioMAE
- Мультимасштабні спектрограми: одночасне використання різних параметрів вікна STFT
- Сильні аугментації: MixUp, CutMix, SpecAugment, Soundscape Mixup

Відмінності BirdCLEF+ 2026:

- Тропічні водно-болотні угіддя Пантаналу замість Середземномор'я, інший акустичний фон, більше перекриття видів
- Більше охоплення видів: 234 види (птахи + амфібії + ссавці + рептилії + комахи)
- Частина видів присутня лише у labeled train_soundscape


Exploratory Data Analysis

Для кращого розуміння структури даних, та формування стратегії навчання моделі було проведено EDA. Основна увага приділялася аналізу train.csv та

візуальному дослідженню аудіофайлів за допомогою мел-спектрограм.

Аналіз метаданих та розподілу класів


Датасет змагання містить аудіозаписи для 234 унікальних класів. Аналіз розподілу кількості записів для кожного класу виявив сильний класовий дисбаланс. Деякі найпопулярніші види птахів мають велику кількість аудіозаписів, що створює ризик перенавчання моделі саме на ці класи. Значна кількість видів представлена дуже малою кількістю файлів.



Географічний та часовий розподіл


Більшість аудіозаписів у тренувальному наборі даних зібрані з платформи Xeno-canto ентузіастами.

Аналіз координат показує концентрацію записів у специфічних регіонах (наприклад, Південна Америка).



Якість записів

Ознака rating у метаданих вказує на якість аудіозапису. Більшість файлів мають високий рейтинг. Проте, у навчальній вибірці наявна значна кількість записів із рейтингом від 0.0 до 3.5. Такі файли зазвичай містять інтенсивний фоновий шум (дощ, сильний вітер, міські звуки) або запис співу птаха, що знаходиться далеко від мікрофона. Наявність записів з низьким рейтингом вимагає використання надійних методів аугментації під час тренування.




Перетворення аудіо у Mel-Spectrograms

Мел-спектрограма відображає частоту звуку по осі Y та час по осі X, а колір позначає амплітуду у децибелах. Побудова спектрограм під час EDA дозволила зробити наступні висновки:

Різні види птахів мають чітко відмінні візуальні сигнатури на спектрограмах (короткі імпульси, специфічні частотні діапазони).

На багатьох графіках видно горизонтальні смуги в нижніх частотах (шум вітру/води) або у високих частотах (спів комах).



Проведений аналіз сформував такі висновки:

Аудіофайли необхідно нарізати на фіксовані фрагменти, щоб узгодити тренувальні дані з форматом тестових soundscapes.

Для боротьби з екстремальним дисбалансом класів необхідно використовувати алгоритми стратифікації (Stratified K-Fold) при розбитті на тренувальний та валідаційний набори.

Для підвищення стійкості моделі до фонового шуму та мультилейбл-природи даних, застосовувати специфічні методи аугментації даних

Валідаційна стратегія

Для оцінки моделей використовувалась стратифікована k-fold крос-валідація

(Stratified K-Fold, $k=5$) з розбивкою за колонкою `primary_label`. Тренування проводилось на fold 0 (80% даних), валідація, на відповідному hold-out фолді (20% даних). Labeled soundscape сегменти додавались виключно до тренувальної частини кожного фолду, щоб уникнути data leakage. Валідація проводилась лише на чистих xeno-canto/iNat кліпах для консистентності між підходами.

Важливість валідації для цього змагання

Основний ризик при розробці валідації - domain gap між тренувальними даними (короткі чисті кліпи з xeno-canto) та тестовими (1-хвилинні польові soundscape записи з накладенням шумів та кількох видів одночасно). Через це валідаційний AUC систематично вищий за Leaderboard score, що підтвердилось результатами.

Аналіз запропонованої метрики

Головною метрикою, запропованою організаторами, є Macro ROC AUC. Вона пропускає класи без жодного позитивного прикладу у тест-сеті.

Переваги: не штрафує за відсутні у тесті класи, добре підходить для сильно незбалансованих датасетів.

Недоліки: не відображає точність порогу класифікації, може бути оптимістичним якщо є небагато активних класів.

Запропоновані альтернативні метрики:

Щоб отримати більш комплексну картину під час валідації, до процесу оцінювання пропонується додати наступні метрики:

PR AUC (Area Under the Precision-Recall Curve): На відміну від ROC AUC, крива Precision-Recall взагалі не враховує True Negatives. Вона фокусується виключно на здатності моделі знаходити правильні класи (Recall) та не робити хибних спрацьовувань (Precision). Для рідкісних видів птахів ця метрика є набагато більш жорсткою та об'єктивною, оскільки показує реальну здатність моделі виявляти цільовий сигнал у зашумленому середовищі.

Macro F1-Score: Для обчислення F1-Score необхідно зафіксувати конкретний поріг відсікання (наприклад, 0.5 або оптимізований поріг для кожного класу). Це дозволяє оцінити, скільки саме правильних спрацьовувань видасть модель на практиці під час інференсу.

Спільне використання Macro ROC AUC разом із PR AUC та F1-Score забезпечує надійну стратегію валідації та мінімізує ризик перенавчання моделі на специфіку тренувального набору даних.

Macro ROC-AUC є найкращим вибором для цієї задачі, оскільки тест-сет містить лише підмножину з 234 видів і метрика автоматично ігнорує відсутні, інші є хорошим доповненням.

Опис використаних підходів

Спільний пайплайн

Всі підходи базуються на однаковій основі:

- Аудіо завантажується фрагментами по 5 секунд (32 kHz, mono)
- Мел-спектрограма розмірністю 128×31
- Нормалізація до [0,1] за мінімумом та максимумом кожного кліпу
- Спектрограма повторюється у 3 канали для сумісності з ImageNet-pretrained моделями
- Архітектура: CNN backbone (timm) → GlobalAvgPool → Dropout(0.3) → Linear(num_classes)
- Функція втрат: BCEWithLogitsLoss (multi-label, soft labels 0.5 для secondary species)
- Оптимізатор: AdamW (lr=1e-3, weight_decay=1e-4), scheduler: CosineAnnealingLR
- Mixed precision training (torch.cuda.amp)
- Labeled soundscape сегменти додавались до тренувальних даних

Approach 1: EfficientNet-B0 (Baseline)

Найпростіший підхід без додаткових аугментацій, служить базовою лінією для порівняння.

Параметр	Значення
Backbone	EfficientNet-B0 (pretrained ImageNet)
Препроцесинг	Log-Mel spectrogram
Аугментації	Time-shift ($\pm 1s$), Gaussian noise ($\sigma=0.005$)
MixUp	Вимкнено
SpecAugment	Вимкнено
Epochs	10
Batch size	32
Параметрів моделі	5.3 M

Approach 2: EfficientNet-B2 + MixUp + SpecAugment

Покращений підхід з більшою моделлю та регуляризуючими аугментаціями для зменшення перенавчання та покращення узагальнення на soundscape домен

Параметр	Значення
Backbone	EfficientNet-B2 (pretrained ImageNet)
Препроцесинг	Log-Mel spectrogram
MixUp	Увімкнено, $\alpha=0.5$ (Beta distribution)
SpecAugment	2 freq masks (max 20 bins) + 2 time masks (max 40 steps)
Epochs	10
Batch size	32
Параметрів моделі	9.1 m

MixUp: кожен батч змішується з іншим випадковим батчем за коефіцієнтом $\lambda \sim \text{Beta}(0.5, 0.5)$. Це змушує модель вчитись на лінійних інтерполяціях між прикладами та їх мітками, що підвищує стійкість до перенавчання та покращує калібрування ймовірностей. SpecAugment: маскує випадкові частотні та часові смуги у спектрограмі, емулюючи часткове перекриття сигналу шумом.

Approach 3: EfficientNet-B1 + PCEN

Підхід відрізняється альтернативним препроцесингом: замість log-mel використовується PCEN (Per-Channel Energy Normalization), адаптивна нормалізація, розроблена спеціально для пасивного акустичного моніторингу

Параметр	Значення
Backbone	EfficientNet-B1 (pretrained ImageNet)
Препроцесинг	PCEN (Per-Channel Energy Normalization)
MixUp	Увімкнено, $\alpha=0.3$
SpecAugment	2 freq masks (max 15 bins) + 2 time masks (max 30 steps)
Epochs	10
Batch size	32
Параметрів моделі	7.8 M

PCEN нормалізує енергію каналу за допомогою локального часового фільтру, що адаптивно пригнічує стаціонарний фоновий шум та підсилює транзйєнтні сигнали. На відміну від log-mel, PCEN не залежить від абсолютного рівня гучності, що є важливим для польових записів з різними умовами.

Approach 4: ConvNeXt-Small + Test-Time Augmentation

Досліджує використання архітектури. Основний акцент зроблено на підвищення стабільності моделі під час інференсу за допомогою ТТА.

Параметр	Значення
Backbone	ConvNeXt-Small (pretrained ImageNet)
Препроцесинг	Log-Mel spectrogram
Інференс стратегія	Test-Time Augmentation (ТТА = 3 проходи)
Шум при ТТА	Gaussian noise ($\sigma=0.003$) для проходів > 1
Batch size	64

Test-Time Augmentation: Замість одного прогону тестових даних через мережу, кожне вікно аудіо аналізується 3 рази: один раз у чистому вигляді, і два рази з додаванням різного випадкового гауссівського шуму. Кінцева ймовірність наявності птаха обчислюється як середнє арифметичне прогнозів усіх трьох проходів. Це значно згладжує невпевненість моделі та знижує кількість False Positives на незнайомих фонoвих звуках.

Кореляція валідаційних метрик та Leaderboard:

Підхід	Архітектура та особливості	Val AUC (OOF)	LB AUC (Public)	Gap (Val - LB)
Approach 1	EfficientNet-B0 (Baseline)	0.970	0.830	0.140
Approach 2	EfficientNet-B2 + MixUp + SpecAug	0.980	0.840	0.140
Approach 3	EfficientNet-B1 + PCEN	0.960	0.809	0.160
Approach 4	EfficientNet-B4 + ConvNeXt-Small + Test-Time Augmentation	0.502	0.534	-0.028
Approach 4 (Full)	EfficientNet-B4 + ConvNeXt-Small + Test-Time Augmentation (all data)	N/A	0.655	

Основний ризик при розробці валідації: domain gap між тренувальними даними та тестовими. Через це валідаційний AUC на класичних підходах систематично вищий за Leaderboard скор.

Проблема Domain Shift: У Підходах 1, 2 та 3 валідаційний показник наближається до ідеального (~0.96-0.98), оскільки модель перевіряється на відносно чистих кліпах. Проте на тестових даних Leaderboard якість падає в середньому на 0.14 - 0.16. Найкращий баланс показав Approach 2, що показало ефективність MixUp та SpecAugment.

Використання PCEN хоч і є теоретично правильним для пасивного акустичного моніторингу, проте дало нижчий результат (0.800) для Approach 3: . Це пов'язано з тим, що адаптивна нормалізація PCEN потребує значно тоншого налаштування гіперпараметрів та більшої кількості епох для збіжності.

Використання архітектури ConvNeXt (Approach 4): показало суттєво нижчий результат (0.530) при стандартному тренуванні на одному фолді. Це пояснюється тим, що "важкі" Transformer-подібні та чисті згорткові архітектури нового покоління є дуже вимогливими до обсягу даних і схильні до перенавчання на невеликих специфічних датасетах без агресивного pre-training.

Вплив навчання на всіх даних: архітектуру ConvNeXt було перенавчено на всіх доступних даних (без виділення валідаційного фолду). Це дало приріст результату на Leaderboard.

Порівняння з попередніми змаганнями:

Паралелі з результатами команд-переможців попередніх років та висновки щодо складності задачі:

1. Вплив зміни метрики:

У змаганнях 2022–2024 років офіційною метрикою була cmAP (competition macro Average Precision). Тоді топові рішення на Leaderboard зазвичай досягали значень 0.65 – 0.75, оскільки cmAP дуже суворо штрафує за False Positives.

2. Стабільність розриву доменів:

У 2024 та 2025 роках розрив між локальною валідацією та LB у більшості учасників становив від 0.10 до 0.20 пунктів. Мої результати відтворюють цю тенденцію.

3. Ефективність архітектур (EfficientNet vs. ConvNeXt):

В змаганнях з розпізнавання аудіо (BirdCLEF 2021-2023) EfficientNet було абсолютним лідером завдяки чудовому співвідношенню швидкості та якості виділення ознак зі спектрограм. Мій експеримент це підтверджує

Висновки:

- Найкращим підходом виявився Approach 2 (EfficientNet-B2 + MixUp + SpecAugment): Val AUC = 0.980, LB AUC = 0.840. Комбінація більшої моделі з регуляризуючими аугментаціями дає найкраще узагальнення на domain-shifted тест-сет.
- Domain gap ~ 0.14 між валідацією та LB є основною проблемою.
- Labeled soundscape сегменти є критично важливими для покриття видів, відсутніх у xeno-canto/iNat кліпах.
- Старіша та легша модель EfficientNet-B2 (Approach 2) показала LB = 0.840, тоді як сучасніша ConvNeXt-Small (Approach 4) показала лише 0.530.

Гіпотеза: Архітектури нового покоління мають значно більшу ємність і менше вбудованих inductive biases. Це робить їх надзвичайно жадібними до даних. На відносно невеликому датасеті BirdCLEF ConvNeXt швидко перенавчається на тренувальному наборі, і втрачає здатність до узагальнення. EfficientNet, навпаки, є більш ефективним для задач такого масштабу.

- Використання PCEN (Approach 3) замість Log-Mel спектрограми призвело до падіння результату (LB = 0.800).

Гіпотеза: PCEN є потужним інструментом для пригнічення стаціонарного шуму. Однак параметри PCEN (такі як константи згладжування, коефіцієнти

посилення) є дуже чутливими до конкретного акустичного середовища. Оскільки Пантанал має унікальний звуковий профіль (багато низькочастотних шумів боліт та високочастотних комах), використання стандартних або погано оптимізованих параметрів PCEN могло призвести до зникнення корисних транз'єнтних сигналів (співу птахів) разом із шумом.